

ASANSÖR KUMANDA SİSTEMLERİ İÇİN TALEP TAHMİNİ:

*Klasik Zaman Serisi Analizinden Modern Gelişmiş İstatistiksel ve Yapay
Zeka modellerine Bir Vaka Çalışması*

Hazırlayan: **Gülnaz Aydemir**
Ostim Teknik Üniversitesi | 2025

Problem

- MRC firmasında 3 ürüne ait talep verileri: gürültülü ve düzensiz.
- Klasik yöntemler ani talep sıçramalarını yakalayamıyor.
- üretim planlama aksaklıkları,
- gereksiz stok (maliyet),
- stoksuz kalma (kayıp satış) risklerine yol açmaktadır.
- Hatalı tahmin → stok fazlası veya stoksuzluk riski.



Veri Seti

- 24 dönemlik (haftalık / 2 haftada bir) satış verileri
- Ürünler:
 - 5.5 KW inverterli kumanda sistemleri
 - 7.5 KW inverterli kumanda sistemleri
 - 11 KW inverterli kumanda sistemleri
- Değişkenler: Tarih, Ürün, Satış

Tarih	Urun_Kodu	Satis_Adedi
15.01.2024	7.5KW	16
28.01.2024	7.5KW	16
15.02.2024	7.5KW	20
28.02.2024	7.5KW	12
15.03.2024	7.5KW	15
28.03.2024	7.5KW	20
15.04.2024	7.5KW	18
28.04.2024	7.5KW	24
15.05.2024	7.5KW	21
28.05.2024	7.5KW	17
15.06.2024	7.5KW	16
28.06.2024	7.5KW	19
15.07.2024	7.5KW	20
28.07.2024	7.5KW	12
15.08.2024	7.5KW	18
28.08.2024	7.5KW	19
15.09.2024	7.5KW	21
28.09.2024	7.5KW	14
15.10.2024	7.5KW	16
28.10.2024	7.5KW	18
15.11.2024	7.5KW	19
28.11.2024	7.5KW	17
15.12.2024	7.5KW	15
28.12.2024	7.5KW	19

Grafik: 7.5 KW inverterli kumanda sistemi haftalık satış verileri

Literatür Taraması

01

Gerçek KOBİ Odaklılık
Kısıtlı ve Gürültülü Veri

02

Endüstriyel B2B Ürün Odaklılık

03

Yöntemsel Yaklaşım (Vaka Analizi)

04

Temel Araştırma Sorusu

“Veri az ve kirliyen bile, Gelişmiş Yapay Zeka Modelleri (Prophet, LSTM), klasik yöntemlerden , daha iyi performans göstererek KOBİ'ler için çözüm üretebilir mi?”

Klasik Yöntemlerin Uygulanması


- Basit Hareketli Ortalama
- Üstel Düzeltme
- Trend Analizi
- Mevsimsellik Analizi

Klasik Yöntemlerin Uygulanması


7,5 KW İnverterli Asansör Kumanda Sistemi İçin 6 Dönemlik BHO

7,5 KW İNVERTERLİ ASANSÖR KUMANDA SİSTEMİ İÇİN 6 DÖNEMLİK BHO							
Aylar	Dönem	Satışlar	6 Dönemlik BHO	Tahmin Hatası	Mutlak Hata	Hata ²	Mutlak Yüzdelik Hata
Ocak	1. Hafta	16					
	2. Hafta	16					
Şubat	1. Hafta	20					
	2. Hafta	12					
Mart	1. Hafta	15					
	2. Hafta	20					
Nisan	1. Hafta	18	16.50	1.50	1.50	2.25	8.33
	2. Hafta	24	16.83	7.17	7.17	51.36	29.86
Mayıs	1. Hafta	21	18.17	2.83	2.83	8.03	13.49
	2. Hafta	17	18.33	-1.33	1.33	1.78	7.84
Haziran	1. Hafta	16	19.17	-3.17	3.17	10.03	19.79
	2. Hafta	19	19.33	-0.33	0.33	0.11	1.75
Temmuz	1. Hafta	20	19.17	0.83	0.83	0.69	4.17
	2. Hafta	12	19.50	-7.50	7.50	56.25	62.50
Ağustos	1. Hafta	18	17.50	0.50	0.50	0.25	2.78
	2. Hafta	19	17.00	2.00	2.00	4.00	10.53
Eylül	1. Hafta	21	17.33	3.67	3.67	13.44	17.46
	2. Hafta	14	18.17	-4.17	4.17	17.36	29.76
Ekim	1. Hafta	16	17.33	-1.33	1.33	1.78	8.33
	2. Hafta	18	16.67	1.33	1.33	1.78	7.41
Kasım	1. Hafta	19	17.67	1.33	1.33	1.78	7.02
	2. Hafta	17	17.83	-0.83	0.83	0.69	4.90
Aralık	1. Hafta	15	17.50	-2.50	2.50	6.25	16.67
	2. Hafta	19	16.50	2.50	2.50	6.25	13.16
					OMS	HKO	OMYH
					2.49	10.23	14.76

Klasik Yöntemlerin Uygulanması




Klasik Yöntemlerin Uygulanması



trend
+
mevsimsellik
+
ani sıçramalar

Klasik Yöntemlerin Uygulanması




Yapay Zeka Modellerinin Uygulanması


Verideki karmaşık desenleri öğrenmek için:

- SARIMA
- Prophet
- LSTM

Yapay Zeka Modellerinin Uygulanması




Yapay Zeka Modellerinin Uygulanması



Yapay Zeka Modellerinin Uygulanması

SARIMA:



Yapay Zeka Modellerinin Uygulanması

SARIMA:



Yöntem

- auto_arima (Otomatik Hiperparametre Optimizasyonu)
- (P,D,Q) lar arasından (AIC) en düşük olan modeli seçti.



Seçilen Model

- ARIMA(0, 0, 0)
- AIC Değeri: 112.81 (Modelin veri setine uyum başarısı).
- Algoritma, n=24 gibi kısıtlı bir veride karmaşık terimler kullanmanın "aşırı öğrenmeye" (overfitting) yol açacağını tespit etti ve en kararlı yapıyı seçti.



Performans Sonuçları

- RMSE (Hata Karekökü): 2.10 Adet.
- MAPE (Başarı Skoru): %12.38
- Kazanım: Baseline yöntemine (%14.76) göre hata oranı %16 iyileştirildi.

Yapay Zeka Modellerinin Uygulanması

Makine Öğrenmesi ve Derin Öğrenme: Veri Kısıtlılığı Analizi



PROPHET

Sonuç: %34.45 MAPE

- Gürültü vs. Sinyal: Prophet, büyük veri setlerinde "yıllık mevsimselliği" (yearly seasonality) yakalamak üzere tasarlanmıştır.
- Veri Yetersizliği:
 - Elimizdeki 24 veri noktası, yetersiz kalmıştır.
 - Model, gerçek satış değişimlerini "gürültü" sanarak aşırı düzleştirme yapmıştır.



LSTM (Long Short-Term Memory)

Sonuç: Uygulanamadı

- LSTM, geçmişe bakarak (Look_Back=4) öğrenen bir mimaridir.
- Veri Kısıtlılığı : Test setimizdeki veri sayısı (2), modelin ihtiyaç duyduğu girdi penceresinden (4) küçük olduğu için model matematiksel olarak çalıştırılamamıştır.
- Kritik Bulgu: n=24 gibi mikro veri setlerinde Derin Öğrenme kullanmak teknik olarak mümkün değildir.

Karşılaştırma Tablosu

Model	Yöntem Kategorisi	MAPE(OMYH)	RMSE	AIC /Bulgu
BHO/ES	Geleneksel	%14.76	3.84	Baseline Referans Değer
SARIMA	Gelişmiş İstatistik	%12.38	2.10	En Düşük Hata ve En İyi Uyum.
Prophet	Makine Öğrenmesi	%34.45	7.67	Veri azlığı/Gürültüye duyarlı.
LTSM	Derin Öğrenme	Uygulanamadı	Uygulanamadı	Veri Kısıtlılığı nedeniyle matematiksel hata.

Sonuç

- Hata oranı %14.76 → %12.38 (yaklaşık %16 iyileşme)
- Daha iyi stok yönetimi
- Daha düşük üretim dalgalanması
- Maliyet azaltımı



TEŞEKKÜRLER

Gölnaz Aydemir Ç220204019
Ostim Teknik Üniversitesi | 2025